

Informe Practica G1 - ETL de Ciberseguridad

Dominio seleccionado: ciberseguridad y monitoreo de incidentes de red. La data fue tomada desde Kaggle Search usando el dataset publico Cyber Security Attacks.

Entregable	Archivo
Compose	docker-compose.yml
Variables	.env
Notebook S1	desarrolloG1.ipynb
Notebook S2	TransformG1.ipynb
Evidencias	evidencias/*.png
Reporte	output/pdf/informe_practica_g1.pdf

Evidencias de ejecucion

Captura 1. Busqueda en Kaggle del dataset de ciberseguridad.

← cyber security attacks

Q X

<> Notebooks 304

Datasets 196

Topics 75

Hugging Face Models 64

Models 9

Comments 8

Competitions 2

Filter by

658 Results

Relevance ▾

DATE

Last 90 days

75

This week

7

Today

1

CREATOR

You

0

Others

594

TOPIC TYPE

Writeups

46

All Topics and Writeups

75

WRITE UP TYPE

Global Cybersecurity: Geospacial EDA and Insights

80

Cyber Security Attacks

Dataset · 15d ago · by Inciribo

Consists of 25 varied metrics and 40,000 records

37,025 downloads

Cyber Attack EDA

Notebook · 2y ago · by Saadat Khalid

Overview: __ Source: __ Dataset is taken from [Kaggle](https://www.kaggle.com/datasets/teaminciribo/cyber-secu...14 comments

430

Cybersecurity AI in 2022-2023

Notebook · 3y ago · by Georgii Vyshnia

Cyber-Attacks on AI Systems: Security for AI vs.

40 comments

312

Comment on:

Discussion Comment · 4mo ago · by maria nadeem

In the [Dataset no longer available] forum

0 replies

0

Kaggle uses cookies from Google to deliver and enhance the quality of its services and to analyze traffic.

Learn more

OK, Got it.

Captura 2. Ejecucion exitosa de Docker Compose y contenedor PostgreSQL activo.

Evidencia Docker Compose y contenedor activo

```
$ docker compose up -d

$ docker compose ps
NAME                IMAGE              COMMAND                  SERVICE      CREATED        STATUS      PORTS
practica_g1_postgres postgres:16-alpine "docker-entrypoint.s..." postgres     6 days ago     Up 9 seconds (healthy) 0.0.0.0:5433->5432/tcp

$ docker inspect -f '{{.State.Health.Status}}' practica_g1_postgres
healthy
```

Captura 3. Notebook Semana 1 ejecutado con DataFrames y analisis.

Desarrollo G1 - Practica ETL Semana 1

Dominio de negocio: ciberseguridad y monitoreo de incidentes de red.

Fuente de datos: Kaggle, dataset [teamincirbo/cyber-security-attacks](#).

Objetivo: configurar PostgreSQL en Docker, cargar una tabla de hechos de alertas de red y analizar tres fuentes relacionadas: PostgreSQL, CSV y JSON.

1. Configuración inicial

Las credenciales de PostgreSQL se leen desde `.env`. Esto evita escribir usuarios, claves o puertos directamente en las celdas del notebook.

```
In [1]: from pathlib import Path
import os

import pandas as pd
from dotenv import load_dotenv
from sqlalchemy import create_engine

load_dotenv()
RAW_DIR = Path('data/raw')
postgres_url = (
    f"postgresql+psycopg2://{os.environ['POSTGRES_USER']}:{os.environ['POSTGRES_PASSWORD']}@"
    f"@{os.environ.get('POSTGRES_HOST', 'localhost')}:{os.environ.get('POSTGRES_PORT', '5432')}/{os.environ['POSTGRES_DB']}"
)
engine = create_engine(postgres_url)
sorted(p.name for p in RAW_DIR.iterdir())

Out[1]: ['asset_inventory.csv',
'cybersecurity_attacks.csv',
'vulnerability_catalog.json']
```

2. DataFrame 1 - PostgreSQL: network_alerts

Este DataFrame proviene de la base PostgreSQL levantada con Docker. La tabla `network_alerts` funciona como tabla de hechos del proyecto SOC, con eventos,

Captura 4. Notebook Semana 2 ejecutado con limpieza y transformación.

TransformG1 - Practica ETL Semana 2

Grupo: G1

Integrante: Carlos Diaz

Proyecto: ciberseguridad y monitoreo de incidentes de red. Este notebook documenta limpieza, normalización, transformación y validación de tres fuentes relacionadas: alertas de red, inventario de activos y catálogo de vulnerabilidades.

1. Exploración inicial de fuentes

Se revisan estructura, filas, columnas, tipos de datos, nulos, duplicados y posibles llaves de relación. Las columnas principales de relación son `machine_id`, `attack_type`, `protocol` y `severity_level`.

```
In [1]: from pathlib import Path
import os

import pandas as pd
from dotenv import load_dotenv

load_dotenv()
RAW_DIR = Path('data/raw')
alerts_raw = pd.read_csv(RAW_DIR / 'cybersecurity_attacks.csv')
assets_raw = pd.read_csv(RAW_DIR / 'asset_inventory.csv')
vulns_raw = pd.read_json(RAW_DIR / 'vulnerability_catalog.json')
{
    'alerts': alerts_raw.shape,
    'assets': assets_raw.shape,
    'vulnerabilities': vulns_raw.shape,
}

Out[1]: {'alerts': (10000, 25), 'assets': (250, 8), 'vulnerabilities': (27, 8)}

In [2]: summary = []
for name, frame in {'alerts': alerts_raw, 'assets': assets_raw, 'vulnerabilities': vulns_raw}.items():
```

Captura 5. Repositorio público creado en GitHub.



ceduardodch / practica-g1-etl-kaggle Public

Notifications

Fork 0

Star 0

Code Issues Pull requests Actions Projects Security and quality Insights

main

1 Branch 0 Tags

Go to file

Code



ceduardodch Add final report with evidence

f1b3348 · now

2 Commits

data/raw

Create ETL practice deliverables

1 minute ago

evidencias

Add final report with evidence

now

output/pdf

Add final report with evidence

now

scripts

Create ETL practice deliverables

1 minute ago

.env

Create ETL practice deliverables

1 minute ago

.gitignore

Create ETL practice deliverables

1 minute ago

README.md

Create ETL practice deliverables

1 minute ago

desarrolloG1.ipynb

Create ETL practice deliverables

1 minute ago

docker-compose.yml

Create ETL practice deliverables

1 minute ago

requirements.txt

Create ETL practice deliverables

1 minute ago

About

Practica ETL G1 con Kaggle, Docker, PostgreSQL y Python

Readme

Activity

0 stars

0 watching

0 forks

Report repository

Releases

No releases published

Packages

No packages published

Contributors 1

Resumen tecnico

El flujo descarga datos de ciberseguridad desde Kaggle, genera un inventario CSV y un catalogo JSON, carga la tabla de hechos network_alerts en PostgreSQL y analiza tres DataFrames: PostgreSQL, CSV y JSON. El notebook de Semana 1 cubre primeras filas, nulos, faltantes, estadisticos y agrupaciones. El notebook de Semana 2 cubre exploracion, variables de entorno, limpieza, seleccion de columnas, transformaciones, identificadores y validacion final.

Las reflexiones profesionales solicitadas se encuentran al final de `desarrolloG1.ipynb` y `TransformG1.ipynb`.