

Informe Practica G1 - ETL con Kaggle, Docker, PostgreSQL y Python

Dominio seleccionado: ecommerce/ventas. La data fue tomada desde Kaggle Search usando el dataset publico Brazilian E-Commerce Public Dataset by Olist.

Entregable	Archivo
Compose	docker-compose.yml
Variables	.env
Notebook	desarrolloG1.ipynb
Evidencias	evidencias/*.png
Reporte	output/pdf/informe_practica_g1.pdf

Evidencias de ejecucion

Captura 1. Busqueda en Kaggle del dataset de ecommerce.

← olist brazilian ecommerce

Q X

<> Notebooks 371

Datasets 7

Comments 4

Topics 4

Filter by

386 Results

Relevance ▾

DATE

Last 90 days

41

This week

4

CREATOR

You

0

Others

386

TOPIC TYPE

Writeups

1

All Topics and Writeups

4

WRITE UP TYPE

Project

1

Simple EDA - Sales and Customer Patterns

Notebook · 7y ago · by Leonardo Ferreira

This is a **Brazilian ecommerce** public dataset of orders made at **Olist** Store.

523

9 comments

Olist eCommerce-Analytics, Quasi Poisson+Poly Regs

Notebook · 6y ago · by Solve for Fun

Brazilian eCommerce Olist**[https://www.kaggle.com/anshumoudgil/olist-e-commerce-analytics-clusters-poly-eq... 78 comments

628

Ecommerce_Brazil_Predictions

Notebook · 5y ago · by Luiz Bueno

This is a **Brazilian ecommerce** public dataset of orders made at **Olist** Store.

152

4 comments

E-Commerce Sentiment Analysis: EDA + Viz + NLP 🚀

Notebook · 6y ago · by Thiago Panini

/input/brazilian-e-commerce' PIPELINES_PATH = './...

1986

86 comments

Joining Marketing Funnel with Brazilian E-Commerce

184

Kaggle uses cookies from Google to deliver and enhance the quality of its services and to analyze traffic.

Learn more

OK, Got it.

Captura 2. Ejecucion exitosa de Docker Compose y contenedor PostgreSQL activo.

Evidencia Docker Compose y contenedor activo

```
$ docker compose up -d

$ docker compose ps
NAME                IMAGE              COMMAND              SERVICE      CREATED          STATUS
practica_g1_postgres postgres:16-alpine "docker-entrypoint.s..." postgres     About a minute ago Up About a minute (healthy)
0.0.0.0:5433->5432/tcp

$ docker inspect -f '{{.State.Health.Status}}' practica_g1_postgres
healthy

$ docker ps --filter name=practica_g1_postgres
CONTAINER ID   IMAGE              COMMAND              CREATED          STATUS          PORTS              NAMES
71a43dbf5b0a  postgres:16-alpine "docker-entrypoint.s..." 2 minutes ago    Up About a minute (healthy)  0.0.0.0:5433->5432/tcp practica_g1_postgres
```

Captura 3. Notebook ejecutado con DataFrames y analisis.

Desarrollo G1 - Practica ETL Semana 1

Dominio de negocio: ecommerce/ventas.

Fuente de datos: Kaggle, dataset [olistbr/brazilian-ecommerce](#).

Objetivo: preparar un entorno ETL con Docker, PostgreSQL y Python, generar tres DataFrames principales y analizar valores nulos, estadísticos y agrupaciones.

1. Configuración inicial

Se cargan librerías, variables de entorno y rutas de trabajo. La base PostgreSQL se levanta con `docker-compose.yml` y sus credenciales se leen desde `.env`.

```
In [1]: from pathlib import Path
import json
import os

import pandas as pd
from dotenv import load_dotenv
from sqlalchemy import create_engine

load_dotenv()
RAW_DIR = Path('data/raw')
postgres_url = (
    f"postgresql+psycopg2://{os.environ['POSTGRES_USER']}:{os.environ['POSTGRES_PASSWORD']}@"
    f"@{os.environ.get('POSTGRES_HOST', 'localhost')}:{os.environ.get('POSTGRES_PORT', '5432')}/{os.environ['POSTGRES_DB']}"
)
engine = create_engine(postgres_url)
RAW_DIR.exists(), sorted(p.name for p in RAW_DIR.iterdir())

Out[1]: (True,
['olist_order_items_dataset.csv',
'olist_orders_dataset.csv',
'product_categories.json',
'product_category_name_translation.csv'])
```

2. DataFrame 1 - PostgreSQL: order items

Captura 4. Repositorio publico creado en GitHub.

The screenshot shows a GitHub repository page for 'ceduardodch/practica-g1-etl-kaggle'. The repository is public and has 0 stars, 0 forks, and 0 watchers. The main branch is 'main'. The repository contains 11 files and folders: 'data/raw', 'evidencias', 'output/pdf', 'scripts', '.env', '.gitignore', 'README.md', 'desarrolloG1.ipynb', 'docker-compose.yml', and 'requirements.txt'. The repository was created 1 minute ago. The right sidebar shows the 'About' section with the description 'Practica ETL G1 con Kaggle, Docker, PostgreSQL y Python'. The 'Releases' section shows 'No releases published'. The 'Packages' section shows 'No packages published'. The 'Contributors' section shows 1 contributor.

Resumen tecnico

El flujo descarga archivos CSV desde Kaggle, convierte una fuente de categorias a JSON, carga el archivo de items de orden en PostgreSQL y analiza tres DataFrames: PostgreSQL, CSV y JSON. Cada DataFrame muestra primeras cinco filas, columnas con nulos, conteo de valores faltantes, estadisticos de variables numericas y maximos/minimos agrupados.

La reflexion profesional solicitada se encuentra al final de `desarrolloG1.ipynb`, bajo la seccion `Aplicacion Profesional de la Practica`.