

Informe Practica G1 - ETL de Ciberseguridad

Dominio seleccionado: ciberseguridad y monitoreo de incidentes de red. La data fue tomada desde Kaggle Search usando el dataset publico Cyber Security Attacks.

Entregable	Archivo
Compose	docker-compose.yml
Variables	.env
Notebook S1	desarrolloG1.ipynb
Notebook S2	TransformG1.ipynb
Evidencias	evidencias/*.png
Reporte	output/pdf/informe_practica_g1.pdf

Evidencias de ejecucion

Captura 1. Busqueda en Kaggle del dataset de ciberseguridad.

← cyber security attacks

Q X

<> Notebooks 304

Datasets 196

Topics 75

Hugging Face Models 64

Models 9

Comments 8

Competitions 2

Filter by

658 Results

Relevance ▾

DATE

Last 90 days

75

This week

7

Today

1

CREATOR

You

0

Others

594

TOPIC TYPE

Writeups

46

All Topics and Writeups

75

WRITE UP TYPE

Global Cybersecurity: Geospacial EDA and Insights

80

Cyber Security Attacks

Dataset · 15d ago · by Inciribo

Consists of 25 varied metrics and 40,000 records

37,025 downloads

Cyber Attack EDA

Notebook · 2y ago · by Saadat Khalid

Overview: __ Source: __ Dataset is taken from [Kaggle](https://www.kaggle.com/datasets/teaminciribo/cyber-secu...14 comments

430

Cybersecurity AI in 2022-2023

Notebook · 3y ago · by Georgii Vyshnia

Cyber-Attacks on AI Systems: Security for AI vs.

40 comments

312

Comment on:

Discussion Comment · 4mo ago · by maria nadeem

In the [Dataset no longer available] forum

0 replies

0

Kaggle uses cookies from Google to deliver and enhance the quality of its services and to analyze traffic.

Learn more

OK, Got it.

Captura 2. Ejecucion exitosa de Docker Compose y contenedor PostgreSQL activo.

Evidencia Docker Compose y contenedor activo

```
$ docker compose up -d

$ docker compose ps
NAME                IMAGE              COMMAND                  SERVICE        CREATED        STATUS        PORTS
practica_g1_postgres postgres:16-alpine "docker-entrypoint.s..." postgres       6 days ago    Up 9 seconds (healthy) 0.0.0.0:5433->5432/tcp

$ docker inspect -f '{{.State.Health.Status}}' practica_g1_postgres
healthy
```

Captura 3. Notebook Semana 1 ejecutado con DataFrames y analisis.

Desarrollo G1 - Practica ETL Semana 1

Dominio de negocio: ciberseguridad y monitoreo de incidentes de red.

Fuente de datos: Kaggle, dataset [teamincirbo/cyber-security-attacks](#).

Objetivo: configurar PostgreSQL en Docker, cargar una tabla de hechos de alertas de red y analizar tres fuentes relacionadas: PostgreSQL, CSV y JSON.

1. Configuración inicial

Las credenciales de PostgreSQL se leen desde `.env`. Esto evita escribir usuarios, claves o puertos directamente en las celdas del notebook.

```
In [1]: from pathlib import Path
import os

import pandas as pd
from dotenv import load_dotenv
from sqlalchemy import create_engine

load_dotenv()
RAW_DIR = Path('data/raw')
postgres_url = (
    f"postgresql+psycopg2://{os.environ['POSTGRES_USER']}:{os.environ['POSTGRES_PASSWORD']}@"
    f"@{os.environ.get('POSTGRES_HOST', 'localhost')}:{os.environ.get('POSTGRES_PORT', '5432')}/{os.environ['POSTGRES_DB']}"
)
engine = create_engine(postgres_url)
sorted(p.name for p in RAW_DIR.iterdir())

Out[1]: ['asset_inventory.csv',
'cybersecurity_attacks.csv',
'vulnerability_catalog.json']
```

2. DataFrame 1 - PostgreSQL: network_alerts

Este DataFrame proviene de la base PostgreSQL levantada con Docker. La tabla `network_alerts` funciona como tabla de hechos del proyecto SOC, con eventos,

Captura 4. Notebook Semana 2 ejecutado con limpieza y transformación.

TransformG1 - Practica ETL Semana 2

Grupo: G1

Integrante: Carlos Diaz

Proyecto: ciberseguridad y monitoreo de incidentes de red. Este notebook documenta limpieza, normalización, transformación y validación de tres fuentes relacionadas: alertas de red, inventario de activos y catálogo de vulnerabilidades.

1. Exploración inicial de fuentes

Se revisan estructura, filas, columnas, tipos de datos, nulos, duplicados y posibles llaves de relación. Las columnas principales de relación son `machine_id`, `attack_type`, `protocol` y `severity_level`.

```
In [1]: from pathlib import Path
import os

import pandas as pd
from dotenv import load_dotenv

load_dotenv()
RAW_DIR = Path('data/raw')
alerts_raw = pd.read_csv(RAW_DIR / 'cybersecurity_attacks.csv')
assets_raw = pd.read_csv(RAW_DIR / 'asset_inventory.csv')
vulns_raw = pd.read_json(RAW_DIR / 'vulnerability_catalog.json')
{
    'alerts': alerts_raw.shape,
    'assets': assets_raw.shape,
    'vulnerabilities': vulns_raw.shape,
}

Out[1]: {'alerts': (10000, 25), 'assets': (250, 8), 'vulnerabilities': (27, 8)}

In [2]: summary = []
for name, frame in {'alerts': alerts_raw, 'assets': assets_raw, 'vulnerabilities': vulns_raw}.items():
```

Captura 5. Repositorio publico creado en GitHub.



data/raw	Switch practice domain to cybersecurity ETL	now
evidencias	Switch practice domain to cybersecurity ETL	now
output/pdf	Switch practice domain to cybersecurity ETL	now
scripts	Switch practice domain to cybersecurity ETL	now
.env	Create ETL practice deliverables	last week
.gitignore	Create ETL practice deliverables	last week
README.md	Switch practice domain to cybersecurity ETL	now
TransformG1.ipynb	Switch practice domain to cybersecurity ETL	now
desarrolloG1.ipynb	Switch practice domain to cybersecurity ETL	now
docker-compose.yml	Create ETL practice deliverables	last week

About

Practica ETL G1 de ciberseguridad con Kaggle, Docker, PostgreSQL y Python

Readme

Activity

0 stars

0 watching

0 forks

Report repository

Releases

No releases published

Packages

No packages published

Resumen tecnico

El flujo descarga datos de ciberseguridad desde Kaggle, genera un inventario CSV y un catalogo JSON, carga la tabla de hechos network_alerts en PostgreSQL y analiza tres DataFrames: PostgreSQL, CSV y JSON. El notebook de Semana 1 cubre primeras filas, nulos, faltantes, estadisticos y agrupaciones. El notebook de Semana 2 cubre exploracion, variables de entorno, limpieza, seleccion de columnas, transformaciones, identificadores y validacion final.

Las reflexiones profesionales solicitadas se encuentran al final de `desarrolloG1.ipynb` y `TransformG1.ipynb`.